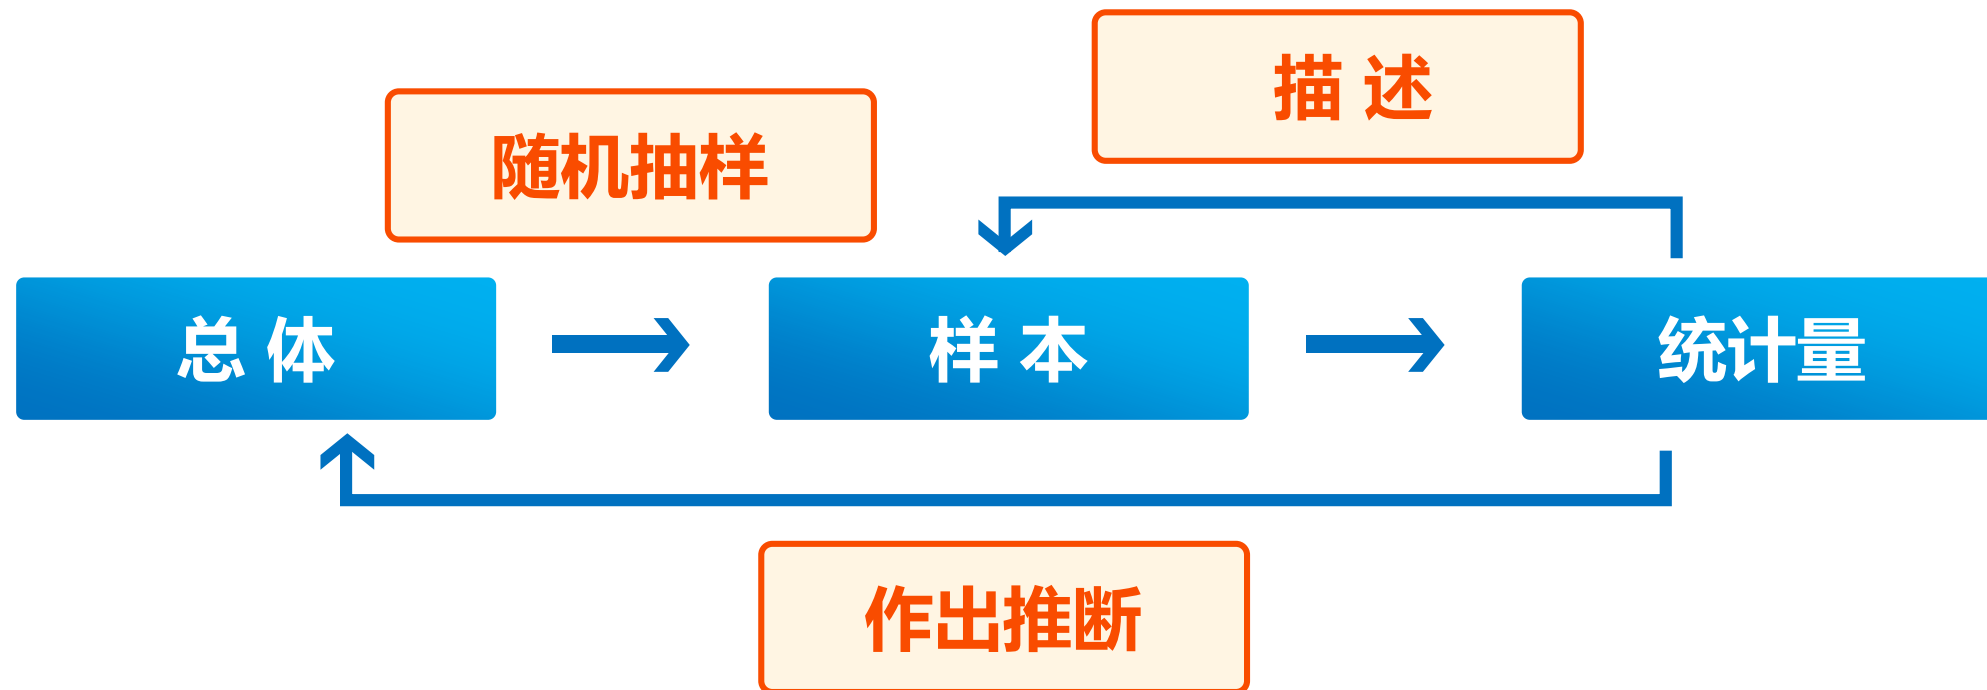


# 概率论与数理统计



# 第18讲

点估计的概念、矩估计和最大似然估计方法



**统计推断：参数估计和假设检验**


数理统计的任务是根据样本所提供的信息，对总体的分布或分布的某些数字特征作推断。

最常见的统计推断问题是总体分布的类型已知，而它的某些参数未知。

例如，已知总体 $X$ 服从正态分布 $N(0, \sigma^2)$ ，其中 $\sigma^2 > 0$ 未知，只要对未知参数 $\sigma^2$ 作出了估计，也就对整个总体分布作出了推断。

**这类问题称为参数估计问题**

参数估计问题是利用样本 $X_1, X_2, \dots, X_n$ 提供的信息，对总体中的未知参数或参数的函数作出估计。



**点估计**——估计未知参数的值

**区间估计**——根据样本构造出适当的区间，使它以一定的概率包含未知参数或未知参数函数的真值。

假如我们要估计某队男生的平均身高。(假定身高服从正态分布  $N(\mu, 0.1^2)$ ), 现从该总体选取容量为5的样本, 分别为

1.65 1.67 1.68 1.71 1.69

求出总体均值 $\mu$ 的估计。

全部信息就由这5个数组成。 估计 $\mu$ 为1.68, 这是点估计。

估计 $\mu$ 在区间 $[1.57, 1.84]$ 内, 这是区间估计。

设总体 $X$ 的分布函数 $F(x, \theta)$ 形式已知,  $\theta$ 是待估参数,  $X_1, X_2, \dots, X_n$ 为抽自总体 $X$ 的样本,  $x_1, x_2, \dots, x_n$ 是相应的一个样本值。据此, 应如何估计未知参数 $\theta$ 呢?

为估计 $\theta$ , 需要构造一个适当的统计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$ , 每当有了样本观测值 $x_1, x_2, \dots, x_n$ , 就代入该统计量中算出一个值  $\hat{\theta}(x_1, x_2, \dots, x_n)$  作为未知参数 $\theta$ 的近似值。

由于未知参数 $\theta$  和  $\hat{\theta}(X_1, X_2, \dots, X_n)$  的取值都是实数轴上的一点, 用  $\hat{\theta}(X_1, X_2, \dots, X_n)$  去估计  $\theta$  等于用一个点去估计另外一个点, 所以这样的估计称为点估计。

**定义2** 设总体 $X$ 的分布为 $f(x, \theta)$ , 其中 $\theta$ 是未知参数,  $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本, 构造统计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$ , 对于样本观察值  $x_1, x_2, \dots, x_n$ , 若将统计量的观察值  $\hat{\theta}(x_1, x_2, \dots, x_n)$  作为未知参数 $\theta$ 的值, 则称  $\hat{\theta}(x_1, x_2, \dots, x_n)$  为参数 $\theta$ 的估计值, 而统计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$  称为参数 $\theta$ 的估计量。 $\theta$ 的估计量和估计值常简记为 $\hat{\theta}$ , 在不引起混淆的情况下统称为 $\theta$ 的估计, 这种估计称为参数的点估计。

若总体分布中含有 $k$ 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ , 则由样本建立 $k$ 个不带任何未知参数的统计量  $\hat{\theta}_i(X_1, X_2, \dots, X_n), i = 1, 2, \dots, k$

将它们分别作为 $k$ 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的点估计量。



矩估计法由英国统计学家卡尔·皮尔逊(Karl Pearson)在20世纪初提出。

### 1.矩估计方法的基本思想

用样本矩估计总体矩



1857-1936

设  $X_1, X_2, \dots, X_n$  为来自总体  $X$  中抽出的一个样本, 则

总体  $k$  阶原点矩为  $\mu_k = E(X^k)$  样本  $k$  阶原点矩为  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

由大数定律  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$  若  $g$  为连续函数, 则  $g(A_k) \xrightarrow{P} g(\mu_k)$

因此, 可以用  $A_k$  估计  $\mu_k$ , 用  $g(A_k)$  估计  $g(\mu_k)$

用样本矩作为相应总体矩的估计量, 样本矩的连续函数作为相应总体矩的连续函数的估计量, 这种估计方法称为**矩估计法**

## 2.矩估计的步骤

设总体 $X \sim F(x, \theta_1, \theta_2, \dots, \theta_k)$ ,  $X_1, X_2, \dots, X_n$ 为样本。

(1) 根据未知参数的个数, 求出总体的各阶矩

$$\mu_l = \mu_l(\theta_1, \dots, \theta_k), l = 1, 2, \dots, k$$

$$\mu_l = E(X^l) = \int_{-\infty}^{+\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx \quad X \text{ 为连续型}$$

总体 $X$ 的密度函数

$$\mu_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k) \quad X \text{ 为离散型}$$

总体 $X$ 的分布律

(2) 解方程(组), 得

$$\theta_l = \theta_l(\mu_1, \dots, \mu_k), l = 1, 2, \dots, k$$

(3) 用样本矩估计相应的总体矩, 即: 用 $A_l$ 替代相应的 $\mu_l$ , 得到 $\theta_l$ 的矩估计

$$\hat{\theta}_l = \theta_l(A_1, A_2, \dots, A_k), l = 1, 2, \dots, k$$

(3)  $g(\theta_1, \dots, \theta_k)$ 的矩估计为

$$g(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$$

例1. 设总体 $X$ 的概率密度为  $f(x) = \begin{cases} (\alpha+1)x^\alpha, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}$

其中 $\alpha > -1$ 是未知参数,  $X_1, X_2, \dots, X_n$ 是取自 $X$ 的样本, 求  
(1) 参数 $\alpha$ 的矩估计; (2)  $g(\alpha) = (\alpha+1)/\alpha$ 的矩估计。

解:(1) 1°. 求总体的1阶矩

$$\mu_1 = E(X) = \int_{-\infty}^{+\infty} xf(x)dx = (\alpha+1) \int_0^1 x^{\alpha+1}dx = \frac{\alpha+1}{\alpha+2}$$

(1) 参数  $\alpha$  的矩估计 (2)  $g(\alpha) = (\alpha+1)/\alpha$  的矩估计。  $\mu_1 = \frac{\alpha+1}{\alpha+2}$

2<sup>0</sup>. 解方程  $\alpha = \frac{2\mu_1 - 1}{1 - \mu_1}$

3<sup>0</sup>. 用  $A_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  代替  $\mu_1$ , 得  $\alpha$  的矩估计为  $\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$

(2)  $g(\alpha) = (\alpha+1)/\alpha$  的矩估计为

$$g(\alpha) = \frac{\hat{\alpha} + 1}{\hat{\alpha}} = \frac{\bar{X}}{2\bar{X} - 1}$$

例2. 设总体 $X$ 的均值 $\mu$ 和方差 $\sigma^2$ 都存在, 且 $\sigma^2 > 0$ , 但 $\mu$ 和 $\sigma^2$ 均未知, 设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 样本, 求 $\mu, \sigma^2$ 的矩估计量。

解: 1<sup>0</sup>. 求总体的1阶矩和2阶矩

$$\begin{cases} \mu_1 = E(X) = \mu \\ \mu_2 = E(X^2) = D(X) + (EX)^2 = \sigma^2 + \mu^2 \end{cases}$$

2<sup>0</sup>. 解方程组

$$\begin{cases} \mu = \mu_1 \\ \sigma^2 = \mu_2 - \mu_1^2 \end{cases}$$

$$\mu = \mu_1, \sigma^2 = \mu_2 - \mu_1^2$$

3<sup>0</sup>. 分别以  $A_1, A_2$  代替  $\mu_1, \mu_2$  得到  $\mu, \sigma^2$  的矩估计量分别为

$$\begin{aligned}\hat{\mu} &= A_1 = \bar{X} \\ \hat{\sigma}^2 &= A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\end{aligned}$$

特别, 若  $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$  未知, 则  $\mu, \sigma^2$  的矩估计量分别为

$$\hat{\mu} = \bar{X} \qquad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$



**例3. 设总体 $X$ 的概率密度函数为  $f(x) = \frac{1}{2\lambda} e^{-\frac{|x|}{\lambda}}, \quad x \in R$**

**其中 $\lambda > 0$ 为未知参数,  $X_1, X_2, \dots, X_n$ 是来自 $X$ 的简单随机样本。求参数 $\theta$ 的矩估计量。**

**解：易知**

$$\mu_1 = E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_{-\infty}^{+\infty} x \frac{1}{2\lambda} e^{-\frac{|x|}{\lambda}} dx = 0$$

**此结果与未知参数 $\lambda$ 无关。**

$$\mu_2 = EX^2 = \int_{-\infty}^{+\infty} x^2 f(x) dx = \int_{-\infty}^{+\infty} x^2 \frac{1}{2\lambda} e^{-\frac{|x|}{\lambda}} dx = \int_0^{+\infty} x^2 \frac{1}{\lambda} e^{-\frac{x}{\lambda}} dx = 2\lambda^2$$

解方程得：

$$\lambda = \sqrt{\frac{\mu_2}{2}}$$

用  $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$  代替  $\mu_2$  得参数  $\lambda$  的矩估计为

$$\hat{\lambda} = \sqrt{\frac{A_2}{2}} = \sqrt{\frac{\sum_{i=1}^n X_i^2}{2n}}$$

优点：直观、简单

缺点：(1) 不唯一，如例1

例1. 设总体 $X$ 的概率密度为  $f(x) = \begin{cases} (\alpha+1)x^\alpha, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}$

其中 $\alpha > -1$ 是未知参数， $X_1, X_2, \dots, X_n$ 是取自 $X$ 的样本，求(1)参数 $\alpha$ 的矩估计；

可以求总体的二阶矩 $\mu_2$ ，用 $A_2$ 代替 $\mu_2$ 得到矩估计。

$$\mu_2 = E(X^2) = \int_{-\infty}^{+\infty} x^2 f(x) dx = (\alpha+1) \int_0^1 x^{\alpha+2} dx = \frac{\alpha+1}{\alpha+3}$$

解方程  $\alpha = \frac{3\mu_2 - 1}{1 - \mu_2}$

用  $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$  代替  $\mu_2$ , 得  $\alpha$  的矩估计为  $\hat{\alpha} = \frac{3A_2 - 1}{1 - A_2}$

显然, 与  $\hat{\alpha} = \frac{2\bar{X} - 1}{1 - \bar{X}}$  不同

规定：用尽量低阶的矩求相应的参数估计

**缺点： (2) 损失信息，如例2**

**例2. 设总体 $X$ 的均值 $\mu$ 和方差 $\sigma^2$ 都存在，且 $\sigma^2 > 0$ ，但 $\mu$ 和 $\sigma^2$ 均未知，设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 样本，求 $\mu, \sigma^2$ 的矩估计量。**


**若已知总体 $X$ 的服从正态分布，则该分布形式已知的信息没有用到，从而造成信息的损失。**

**(3) 有不适用的情况存在。**矩估计方法要求总体的原点矩存在，而有些随机变量(如柯西分布)的原点矩不存在，因此就不能用矩估计方法求点估计。



**Gauss(1777-1855)**

**首先是由德国数学家高斯在1821年提出。**



**Fisher(1890-1962)**

**然而，这个方法常归功于英国统计学家费歇(Fisher)。**

**费歇在1922年重新发现了这一方法，并首先研究了该方法的一些性质。**

### 一. 最大似然估计的基本思想

例4. 某位同学与一位猎人一起外出打猎

一只野兔从前方窜过

只听一声枪响，野兔应声倒下



如果要你推测，是谁打中的呢？

你会如何想呢？



因为只发一枪便打中，猎人命中的概率一般大于这位同学命中的概率。  
看来这一枪是猎人射中的。

其数学模型为

令 $X$ 为打一枪的中弹数，则 $X \sim b(1, p)$ ， $p$ 未知。依题意 $p$ 有两种可能：

$\{0.9, 0.1\}$

$p$ 的取值范围

两人中有一人打枪，估计这一枪是谁打的，即估计总体 $X$ 的参数 $p$ 的值是0.9还是0.1？




## 四. 最（极）大似然估计（MLE）

打了1枪，相当于得到一个样本，记为 $X_1$

兔子中弹，相当于样本观测值为1，即 $\{X_1 = 1\}$ 发生了

考虑此样本观测值出现的概率，有

$$L(p) = P\{X_1 = 1\} = p = 0.9 \text{ 或 } 0.1$$



选择是猎人打的，相当于选择 $p$ 的值，使得样本观测值1出现的可能性最大。

**最大似然估计法的基本思想：**根据样本观测值，选择参数 $p$ 的值，使得该样本值出现的可能性最大。

**说明：**虽然参数 $p$ 可取参数空间 $\Theta$ 中的所有值，但在给定样本观察值 $x_1, x_2, \dots, x_n$ 后，不同的 $p$ 值对应样本 $X_1, X_2, \dots, X_n$ 落入 $x_1, x_2, \dots, x_n$ 的邻域的概率大小也不同，既然在一次试验中观察到 $X_1, X_2, \dots, X_n$ 取值 $x_1, x_2, \dots, x_n$ ，因此有理由认为 $X_1, X_2, \dots, X_n$ 落入 $x_1, x_2, \dots, x_n$ 的邻域中的概率较其它地方大。

哪一个参数使得 $X_1, X_2, \dots, X_n$ 落入 $x_1, x_2, \dots, x_n$ 的邻域中的概率最大，这个参数就是最可能的参数，我们用它作为参数的估计值，这就是**最大似然原理**。

设总体 $X$ 为离散型，其分布列为

$$P\{X=x\}=f(x;\theta)$$

其中 $\theta \in \Theta$ ， $\theta$ 为待估参数， $\Theta$ 是参数空间即参数 $\theta$ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本，则样本 $X_1, X_2, \dots, X_n$ 的分布列为

$$\prod_{i=1}^n f(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是样本 $X_1, X_2, \dots, X_n$ 的一个观察值，易知样本 $X_1, X_2, \dots, X_n$ 取 $x_1, x_2, \dots, x_n$ 的概率，即事件 $\{X_1=x_1, X_2=x_2, \dots, X_n=x_n\}$ 发生的概率为

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta), \quad \theta \in \Theta$$

这一概率随 $\theta$ 的取值而变化，它是 $\theta$ 的函数， $L(\theta)$ 称为样本的**似然函数**。

由最大似然原理，固定样本观察值  $x_1, x_2, \dots, x_n$ ，在  $\theta$  的取值范围  $\Theta$  内挑选使似然函数  $L(\theta)$  达到最大的值  $\hat{\theta}$  作为参数  $\theta$  的估计值，即取使得

$$L(\hat{\theta}; x_1, \dots, x_n) = \max_{\theta \in \Theta} L(\theta; x_1, \dots, x_n)$$

$\hat{\theta}$  与  $x_1, x_2, \dots, x_n$  有关，记做  $\hat{\theta}(x_1, \dots, x_n)$ ，称其为参数  $\theta$  的最大似然估计值；称  $\hat{\theta}(X_1, X_2, \dots, X_n)$  为参数  $\theta$  的最大似然估计量。

设总体 $X$ 为连续型，其密度函数为 $f(x; \theta)$ ，其中 $\theta \in \Theta$ ， $\theta$ 为待估参数， $\Theta$ 是参数空间即参数 $\theta$ 的取值范围。

设 $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本，则样本 $X_1, X_2, \dots, X_n$ 的联合密度函数为

$$\prod_{i=1}^n f(x_i; \theta)$$

又设 $x_1, x_2, \dots, x_n$ 是样本 $X_1, X_2, \dots, X_n$ 的一个观察值，易知样本 $X_1, X_2, \dots, X_n$ 落在 $x_1, x_2, \dots, x_n$ 的邻域（边长分别为 $dx_1, dx_2, \dots, dx_n$ 的维立方体）的概率近似为

$$\prod_{i=1}^n f(x_i; \theta) dx_i$$

这一概率随 $\theta$ 的取值而变化，它是 $\theta$ 的函数，取 $\theta$ 的估计值 $\hat{\theta}$ 使得上式达到最大，但 $\prod_{i=1}^n dx_i$ 不随 $\theta$ 取值的变化而改变，故只需考虑

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta), \quad \theta \in \Theta$$

的最大值， $L(\theta)$ 称为样本的似然函数。

由最大似然原理，固定样本观察值 $x_1, x_2, \dots, x_n$ ，在 $\theta$ 的取值范围 $\Theta$ 内挑选使似然函数 $L(\theta)$ 达到最大的值 $\hat{\theta}$ 作为参数 $\theta$ 的估计值，即取使得

$$L(\hat{\theta}; x_1, \dots, x_n) = \max_{\theta \in \Theta} L(\theta; x_1, \dots, x_n)$$

$\hat{\theta}$ 与 $x_1, x_2, \dots, x_n$ 有关，记做 $\hat{\theta}(x_1, \dots, x_n)$ ，称其为参数 $\theta$ 的最大似然估计值；称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 $\theta$ 的最大似然估计量。



**1.似然函数：** 设总体 $X$ 的概率密度(或分布律)为 $f(x;\theta)$ ,  $\theta \in \Theta$ ,  $X_1, \dots, X_n$ 为来自总体的样本, 则 $(X_1, \dots, X_n)$ 的密度函数(或分布律)为

$$f(x_1; \theta) \cdots f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

若已知样本观测值 $(x_1, \dots, x_n)$ , 则令 $\theta$ 的函数为

$$L(\theta) = L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

称其为基于样本 $(x_1, \dots, x_n)$ 的似然函数。

称  $\ln L(\theta) = \ln L(\theta; x_1, \dots, x_n) = \ln \prod_{i=1}^n f(x_i; \theta)$  为样本的对数似然函数。

**2.最大似然估计：**如果似然函数 $L(\theta; x_1, \dots, x_n)$ ，在 $\hat{\theta}$ 达到最大值，即

$$L(\hat{\theta}; x_1, \dots, x_n) = \max_{\theta \in \Theta} L(\theta; x_1, \dots, x_n)$$

则称 $\hat{\theta}$ 为 $\theta$ 的最大似然估计值。

它一般是 $x_1, \dots, x_n$ 的函数，也常记为 $\hat{\theta}(x_1, \dots, x_n)$   $\hat{\theta}(X_1, \dots, X_n)$  称为最大似然估计量。

在不引起混淆的情况下，统称为最大似然估计(*Maximum Likelihood Estimator*简记为*MLE*)。

### 最大似然估计的求法

求似然函数 $L(\theta; x_1, \dots, x_n)$ 在 $\theta \in \Theta$ 内关于 $\theta$ 的最大值点。

若 $f(x, \theta)$ 关于 $\theta$ 可微，则 $\theta$ 的MLE可由下式得到

$$\frac{dL}{d\theta} = 0$$

似然方程

又因为 $L(\theta)$ 和 $\ln L(\theta)$ 在同一 $\theta$ 处取得极值，因此MLE也可由下述方程得到

$$\frac{d \ln L(\theta)}{d\theta} = 0$$

对数似然方程

当似然函数 $L(\theta)$ 不是 $\theta$ 的可微函数时，此时需要用定义的方法求最大似然估计。

最大似然估计也适用于分布中含多个未知参数  $\theta=(\theta_1, \theta_2, \dots, \theta_k)$  的情况, 此时, 似然函数  $L(\theta)$  是这些未知参数的函数。若似然函数  $L(\theta; x_1, \dots, x_n)$  关于  $\theta$  各分量的偏导数都存在, 则  $\theta=(\theta_1, \theta_2, \dots, \theta_k)$  的最大似然估计可由下述方程组求得

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

又因为  $L(\theta)$  与  $\ln L(\theta)$  在同一  $\theta$  处取得极值, 因此  $\theta=(\theta_1, \theta_2, \dots, \theta_k)$  的最大似然估计也可由下述方程组解得

$$\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

该方程组称为对数似然方程组。利用对数似然方程组求解更方便。

## 最大似然估计的不变性

设总体 $X$ 的分布类型已知, 其概率密度函数(或分布列)为 $f(x, \theta)$ ,  $\theta=(\theta_1, \theta_2, \dots, \theta_k) \in \Theta \subset R^k$ 为未知参数, 参数 $\theta=(\theta_1, \theta_2, \dots, \theta_k)$ 的已知函数为 $g(\theta_1, \theta_2, \dots, \theta_k)$ , 函数 $g$ 具有单值反函数。

若 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别为 $\theta_1, \theta_2, \dots, \theta_k$ 的最大似然估计, 则 $g(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$ 是 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的最大似然估计。

**求最大似然估计(MLE)的一般步骤是：**

- 1. 由总体 $X$ 的分布写出似然函数 $L(\theta)$ ;**
- 2. 求对数似然函数 $\ln L(\theta)$ ;**
- 3. 对  $\ln L(\theta)$  关于  $\theta$  求(偏)导数, 并令(偏)导函数为0;**
- 4. 解方程(组), 得到未知参数的最大似然估计。**

**当以上方法不适用时, 需要从定义出发, 直接求似然函数的极值点。**



**作业：1(矩估计), 2, 5(矩估计)**

# 第 18 讲

谢谢观看