

概率论与数理统计



第19讲

最大似然估计方法、估计量的评选标准

求最大似然估计(MLE)的一般步骤是：

- 1. 由总体 X 的分布写出似然函数 $L(\theta)$;**
- 2. 求对数似然函数 $\ln L(\theta)$;**
- 3. 对 $\ln L(\theta)$ 关于 θ 求(偏)导数，并令(偏)导函数为0;**
- 4. 解方程(组)，得到未知参数的最大似然估计。**

当以上方法不适用时，需要从定义出发，直接求似然函数的极值点。

例1. 设总体 $X \sim b(1, p)$, X_1, X_2, \dots, X_n 是取自 X 的一个样本, x_1, x_2, \dots, x_n 是对应的样本值, 求参数 p 的最大似然估计量。

解: 总体 X 的分布律为

$$P\{X = x\} = p^x (1-p)^{1-x}, x = 0, 1$$

似然函数为
$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}$$

对数似然函数为
$$\ln L(p) = \sum_{i=1}^n x_i \ln p + (n - \sum_{i=1}^n x_i) \ln(1-p)$$

$$\text{对数似然函数为 } \ln L(p) = \sum_{i=1}^n x_i \ln p + (n - \sum_{i=1}^n x_i) \ln(1 - p)$$

对 p 求导并令导函数为0, 得到对数似然方程

$$\frac{d \ln L(p)}{dp} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} (n - \sum_{i=1}^n x_i) = 0$$

解方程得 p 的最大似然估计值为 $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$

最大似然估计量为 $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$

例2 设 X_1, X_2, \dots, X_n 是取自总体 X 的一个样本

$$X \sim f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & \text{其它} \end{cases} \quad \text{其中 } \theta > 0$$

求 θ 的最大似然估计。

解：似然函数为

$$L(\theta) = f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1}$$

对数似然函数为 $\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$

$$\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$$

求导并令其为0

$$\frac{d \ln L(\theta)}{d \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$$

从中解得

$$\hat{\theta} = -n / \sum_{i=1}^n \ln x_i$$

即为 θ 的MLE。

例3. 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, X_1, X_2, \dots, X_n 是取自总体 X 的一个样本, x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的一个样本值, 求 (1) 参数 μ, σ^2 的最大似然估计量 (2) σ 的最大似然估计量。

解: X 的密度函数为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

似然函数为

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x_i - \mu)^2\right\}$$

对数似然函数为

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

对 μ, σ^2 分别求偏导并令导数为0，得到对数似然方程组

$$\begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} [\sum_{i=1}^n x_i - n\mu] = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

解得 μ, σ^2 的最大似然估计值为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

最大似然估计量为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

由于

$$\sigma = \sqrt{\sigma^2}$$

所以 σ 最大似然估计量为

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

例4. 设总体 X 的概率分布为

X	0	1	2
P	θ	$1-2\theta$	θ

其中 $0 < \theta < 1/2$ 为未知参数. 今对 X 进行观测, 得如下样本值

0, 1, 2, 0, 2, 1

求 θ 的最大似然估计。

解: 依题意 0, 1, 2, 0, 2, 1 是来自总体 X 的 6 个样本 X_1, X_2, \dots, X_6 的观测值
似然函数为

$$L(\theta) = P\{X_1 = x_1\}P\{X_2 = x_2\} \cdots P\{X_6 = x_6\}$$

X	0	1	2
P	θ	$1-2\theta$	θ

$$\begin{aligned}L(\theta) &= P\{X_1 = x_1\}P\{X_2 = x_2\} \cdots P\{X_6 = x_6\} \\&= P\{X_1 = 0\}P\{X_2 = 1\}P\{X_3 = 2\}P\{X_4 = 0\}P\{X_5 = 2\}P\{X_6 = 1\} \\&= \theta(1-2\theta)\theta\theta\theta(1-2\theta) = \theta^4(1-2\theta)^2\end{aligned}$$

对数似然函数为 $\ln L(\theta) = 4\ln \theta + 2\ln(1-2\theta)$

求导并令其为0 $\frac{4}{\theta} + 2\frac{-2}{1-2\theta} = 0$ 从中解得 $\hat{\theta} = \frac{1}{3}$

例5. 设总体 $X \sim U(a, b)$, $a < b$ 为未知参数, X_1, X_2, \dots, X_n 是取自总体 X 的一个样本, x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的样本值, 求参数 a, b 的最大似然估计量。

解: X 的密度函数为 $f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}$

a, b 的取值范围
 $-\infty < a < b < +\infty$

似然函数为 $L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_1, x_2, \dots, x_n \leq b \\ 0, & \text{其他} \end{cases}$

对数似然函数为

$$\ln L(a, b) = \ln \frac{1}{(b-a)^n} = -n \ln(b-a)$$

对数似然方程组为

$$\begin{cases} \frac{\partial \ln L(a, b)}{\partial a} = \frac{n}{b-a} = 0 \\ \frac{\partial \ln L(a, b)}{\partial b} = -\frac{n}{b-a} = 0 \end{cases}$$

不能求解。

设 $x_{(1)} = \min(x_1, x_2, \dots, x_n)$, $x_{(n)} = \max(x_1, x_2, \dots, x_n)$

因为 $a \leq x_1, x_2, \dots, x_n \leq b$ 等价于 $a \leq x_{(1)} < x_{(n)} \leq b$, 于是


$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_1, x_2, \dots, x_n \leq b \\ 0, & \text{其他} \end{cases}$$

a, b 的取值范围

$$= \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)} \\ 0, & \text{其它} \end{cases}$$

因此, a 越大、 b 越小, 似然函数 L 越大。

$$L(a,b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)} \\ 0, & \text{其它} \end{cases}$$



对于满足 $a \leq x_{(1)}, x_{(n)} \leq b$ 的任意 a, b 有

$$L(a,b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

即 $L(a,b)$ 在 $a=x_{(1)}, b=x_{(n)}$ 时, 取最大值 $(x_{(n)} - x_{(1)})^{-n}$

$$L(a,b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n}$$

因此 a, b 的最大似然估计值为

$$\hat{a} = x_{(1)} = \min(x_1, x_2, \dots, x_n), \quad \hat{b} = x_{(n)} = \max(x_1, x_2, \dots, x_n)$$

最大似然估计量为

$$\hat{a} = X_{(1)} = \min(X_1, X_2, \dots, X_n), \quad \hat{b} = X_{(n)} = \max(X_1, X_2, \dots, X_n)$$

矩估计法和最大似然估计法的比较

1. 矩估计法对总体分布要求较少;
 2. 最大似然法要求知道总体分布(分布律或密度);
 3. 两种方法的结果有时是一样的, 有时有差别, 最大似然估计相对来说有更多的优良性。
-

对于同一参数，用不同的估计方法求出的估计量可能不相同。



问题：采用哪一个估计量好？


设总体 $X \sim F(x, \theta)$ ，其中 θ 为未知参数， X_1, X_2, \dots, X_n 为来自该总体的样本， $\hat{\theta}(X_1, \dots, X_n)$ 为 θ 的一个估计量。

估计量 $\hat{\theta}(X_1, \dots, X_n)$ 是一个随机变量


当样本 (X_1, \dots, X_n) 有观测值 (x_1, \dots, x_n) 时，估计值为 $\hat{\theta}(x_1, \dots, x_n)$

而当样本 (X_1, \dots, X_n) 有观测值 (y_1, \dots, y_n) 时，估计值为 $\hat{\theta}(y_1, \dots, y_n)$

由不同的观测结果，就会求得不同的参数估计值。因此评价一个估计量的好坏，不能仅仅依据一次试验的结果来判断，而必须根据估计量的分布从整体上来做评价。



当样本值取不同的观测值时，希望相应的估计值在未知参数真值附近摆动，而它的均值与未知参数的真值的偏差越小越好。当这种偏差为0时，就导致无偏性这个标准。




二. 估计量的评选标准 — 无偏性


定义1 (无偏性): 设 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 为未知参数 θ 的估计量, 若对任意的 $\theta \in \Theta$, Θ 为参数空间, 都有

$$E(\hat{\theta}(X_1, \dots, X_n)) = \theta$$

则称 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 为 θ 的无偏估计量。



有 偏



无 偏

记 $E(\hat{\theta}(X_1, \dots, X_n)) - \theta = b_n$, 称 b_n 为估计 $\hat{\theta}(X_1, \dots, X_n)$ 的偏差, 如果 $b_n \neq 0$, 称 $\hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的有偏估计。

若 $\lim_{n \rightarrow \infty} b_n = \lim_{n \rightarrow \infty} [E\hat{\theta}(X_1, X_2, \dots, X_n) - \theta] = 0$ 称 $\hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的渐近无估计。

当样本容量 n 充分大时, 可把渐近无偏估计视作无偏估计。

对于无偏估计量, 单次的估计值相对于真值, 可能偏大, 也可能偏小, 它无法说明一次估计所产生的偏差, 但反复将这一估计量使用多次, 平均来说其偏差为0。

无偏估计量仅在多次重复使用时才显示其优越性。

例6. 设总体 X 的 k 阶原点矩存在, 记其为 μ_k , X_1, X_2, \dots, X_n 为来自总体 X 的样本, 试证明不论总体服从什么分布, 样本 k 阶矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

是总体 k 阶矩 μ_k 的无偏估计量。

解: 由于

$$E(A_k) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} E\left(\sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k) = \mu_k$$

因此样本 k 阶矩是总体 k 阶矩的无偏估计量。

特别, 当 $k=1$ 时, 样本均值 \bar{X} 是总体均值 $E(X)$ 的无偏估计。

二. 估计量的评选标准 — 无偏性

例7. 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 证明: 不论总体 X 服从什么分布, 若总体方差 $D(X)=\sigma^2$ 存在, 则样本二阶中心矩 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 σ^2 的有偏估计, 而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 σ^2 的无偏估计。

证明: 由于
$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2 = \frac{1}{n} \left[\sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \right]$$

其中 $\mu = EX$ 。

所以有
$$E(S_n^2) = \frac{1}{n} \left[\sum_{i=1}^n E(X_i - \mu)^2 - nE(\bar{X} - \mu)^2 \right] = \frac{1}{n} \left[\sum_{i=1}^n \sigma^2 - n \frac{\sigma^2}{n} \right] = \frac{n-1}{n} \sigma^2$$

而 $E(S^2) = \frac{n}{n-1} E(S_n^2) = \sigma^2$ 这正是称 S^2 为样本方差的原因。

例8. 设总体 X 的概率密度为 $f(x, \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

其中 $\theta > 0$ 为未知参数, X_1, X_2, \dots, X_n 为来自总体 X 的样本。

试证: \bar{X} 和 $nU = n\{\min(X_1, X_2, \dots, X_n)\}$ 都是 θ 的无偏估计量。

解: 因为 $E\bar{X} = EX = \theta$ 故 \bar{X} 是 θ 的无偏估计

易求得 X 的分布函数为 $F_X(x) = \begin{cases} 1 - e^{-x/\theta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

$$Z \text{ 的分布函数 } F(u) = 1 - [1 - F_X(u)]^n$$

对其求导数得到Z的密度函数为：

$$f_U(u) = F'(u) = n[1 - F_X(u)]^{n-1} f_X(u)$$

$$= \begin{cases} n[1 - (1 - e^{-u/\theta})]^{n-1} \frac{1}{\theta} e^{-u/\theta}, & u > 0 \\ 0, & u \leq 0 \end{cases}$$
$$= \begin{cases} \frac{n}{\theta} e^{-\frac{n}{\theta}u}, & u > 0 \\ 0, & u \leq 0 \end{cases}$$

$$F_X(x) = \begin{cases} 1 - e^{-x/\theta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

$$f(x, \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

$$Z \text{ 的密度函数为 } f_U(u) = \begin{cases} \frac{n}{\theta} e^{-\frac{n}{\theta}u}, & u > 0 \\ 0, & u \leq 0 \end{cases} = \begin{cases} \frac{1}{\theta/n} e^{-\frac{1}{\theta/n}u}, & u > 0 \\ 0, & u \leq 0 \end{cases}$$

$$E(U) = \int_{-\infty}^{+\infty} u f_U(u) du = \int_0^{+\infty} u \frac{n}{\theta} e^{-\frac{n}{\theta}u} du = \frac{\theta}{n}$$

由指数分布的性质知: $E(U) = \frac{\theta}{n}$

故有: $E(nU) = nE(U) = n \frac{\theta}{n} = \theta$

因此, nU 也是 θ 的无偏估计量。

指数分布

例9. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 总体均值为 $\mu = EX$, 证明 \bar{X} 与 \bar{X}' 都是 μ 的无偏估计。

$$\text{其中 } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{X}' = \sum_{i=1}^n \alpha_i X_i \quad \sum_{i=1}^n \alpha_i = 1$$


证明: 由于 $E\bar{X} = \mu$

$$E\bar{X}' = E\left(\sum_{i=1}^n \alpha_i X_i\right) = \sum_{i=1}^n \alpha_i EX_i = \sum_{i=1}^n \alpha_i \mu = \mu \sum_{i=1}^n \alpha_i = \mu$$

所以都是无偏估计。

一个参数往往有不只一个无偏估计, 若 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 都是参数 θ 的无偏估计量, 比较 $D(\hat{\theta}_1)$ 和 $D(\hat{\theta}_2)$ 的大小来决定二者谁更优。

无偏估计以方差小者为好, 由此引进有效性这一概念。




设 $\hat{\theta}_1(X_1, X_2, \dots, X_n), \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是参数 θ 的无偏估计量

若对任意 $\theta \in \Theta$, 有

$$D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$$

且至少对某一个 $\theta \in \Theta$ 上式中的不等号成立。则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效。



例10. 设总体 X 的概率密度为 $f(x, \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

其中 $\theta > 0$ 为未知参数, X_1, X_2, \dots, X_n 为来自总体 X 的样本, $n > 1$ 。

试比较: \bar{X} 和 $nU = n\{\min(X_1, X_2, \dots, X_n)\}$ 的有效性。

解: 由例2知: \bar{X} 和 nU 都是 θ 的无偏估计量。

且 $U = \min(X_1, X_2, \dots, X_n)$ 的密度函数为 $f_U(u) = \begin{cases} \frac{n}{\theta} e^{-\frac{n}{\theta}u}, & u > 0 \\ 0, & u \leq 0 \end{cases}$

$$U \text{ 的密度函数为 } f_U(u) = \begin{cases} \frac{n}{\theta} e^{-\frac{n}{\theta}u}, & u > 0 \\ 0, & u \leq 0 \end{cases}$$

$$\text{由 } D(X) = \theta^2 \quad \text{得 } D(\bar{X}) = \frac{1}{n} D(X) = \frac{\theta^2}{n}$$

$$\text{又由 } D(U) = \frac{\theta^2}{n^2} \quad \text{得 } D(nU) = n^2 D(U) = n^2 \cdot \frac{\theta^2}{n^2} = \theta^2$$

因此，当 $n > 1$ 时， $D(nU) > D(\bar{X})$ 即： \bar{X} 比 nU 有效。

例11. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 总体均值为 $\mu=EX$, 比较 \bar{X} 与 \bar{X}' 的有效性。

$$\text{其中 } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{X}' = \sum_{i=1}^n \alpha_i X_i \quad \sum_{i=1}^n \alpha_i = 1$$

解: 例9中已经证明 \bar{X} 与 \bar{X}' 都是 μ 的无偏估计。

$$\because \sum_{i=1}^n \alpha_i^2 = \sum_{i=1}^n \left[\left(\alpha_i - \frac{1}{n} \right) + \frac{1}{n} \right]^2 = \sum_{i=1}^n \left(\alpha_i - \frac{1}{n} \right)^2 + \frac{1}{n} \geq \frac{1}{n}$$

$$\therefore D(\bar{X}') = \sum_{i=1}^n \alpha_i^2 D(X_i) = \sum_{i=1}^n \alpha_i^2 \sigma^2 \geq \frac{\sigma^2}{n} = D(\bar{X})$$

等号成立当且仅当 $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$ 所以 \bar{X} 比 \bar{X}' 有效。

总体参数 θ 的点估计 $\hat{\theta}(X_1, \dots, X_n)$ 与样本容量 n 有关, 前面讲的无偏性和有效性都是在样本容量 n 固定的前提下给出的点估计的评价标准。

当用 $\hat{\theta}(X_1, \dots, X_n)$ 去估计 θ 时, 自然要求当 n 越来越大时, 一个估计量的值越来越接近待估参数 θ 的真值, 这就是相合性的评价标准。

定义 设 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为总体分布中未知参数 θ 的估计量, 若对于任意 $\theta \in \Theta$, Θ 为参数空间, 若对于任意 $\theta \in \Theta$ 都满足对于任意 $\varepsilon > 0$, 有

$$\hat{\theta}(X_1, X_2, \dots, X_n) \xrightarrow{P} \theta$$

则称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 θ 的相合估计量。

也说估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 具有相合性。

即对于任意 $\theta \in \Theta$ 都满足: 对于任意 $\varepsilon > 0$, 有

依概率收敛

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1 \quad \text{或} \quad \lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| > \varepsilon\} = 0$$

根据大数定律, 样本 k 阶矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是相应总体 k 阶矩 $\mu_k = E(X^k)$ 的相合估计(假定被估计的总体 k 阶矩存在)。

若待估参数是 $\theta = g(\mu_1, \mu_2, \dots, \mu_k)$, 其中 g 为连续函数, 则 $\theta = g(\mu_1, \mu_2, \dots, \mu_k)$ 的矩估计量 $\hat{\theta} = g(A_1, A_2, \dots, A_k)$ 是 $\theta = g(\mu_1, \mu_2, \dots, \mu_k)$ 的相合估计量。

特别, 样本均值 \bar{X} 与样本二阶中心矩 S_n^2 分别是总体均值 EX 与总体方差 DX 的相合估计。

例12. 设总体 $X \sim U(0, \theta)$, 其中 $\theta > 0$ 为未知参数, X_1, X_2, \dots, X_n 为来自总体 X 的样本。令 $X_{(n)} = \max(X_1, X_2, \dots, X_n)$. 证明: $X_{(n)}$ 是参数 θ 的有偏估计, 但是它是相合的。

证明: 易得 $X_{(n)}$ 的密度函数为
$$f(x) = \begin{cases} \frac{n}{\theta^n} x^{n-1}, & 0 < x < \theta, \\ 0, & \text{其它.} \end{cases}$$

$$\text{所以 } EX_{(n)} = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^{\theta} x \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{n+1} \theta$$

所以 $X_{(n)}$ 是参数 θ 的有偏估计。

对于任意 $\varepsilon > 0$

$$P\{|X_{(n)} - \theta| < \varepsilon\} = \int_{|z-\theta| < \varepsilon} f_{X_{(n)}}(z) dz = \int_{\theta-\varepsilon}^{\theta+\varepsilon} f_{X_{(n)}}(z) dz$$

$$= \int_{\theta-\varepsilon}^{\theta} n z^{n-1} / \theta^n dz = 1 - \left(\frac{\theta - \varepsilon}{\theta}\right)^n$$

$$\lim_{n \rightarrow \infty} P\{|X_{(n)} - \theta| < \varepsilon\} = \lim_{n \rightarrow \infty} \left[1 - \left(\frac{\theta - \varepsilon}{\theta}\right)^n\right] = 1$$

即： $X_{(n)}$ 是参数 θ 的相合估计。

相合性是对一个估计量的基本要求，若估计量不具有相合性，那么无论样本容量 n 取多大，都不能将 θ 估计的足够精确，这样的估计量是不可取的。

无偏性、有效性和相合性是评价估计量的一些基本标准，但不是唯一的标准。



作业：1(MLE),4,7,9,10,11

第 19 讲

谢谢观看